

卒業論文

視覚と行動の end-to-end 学習により
経路追従行動を模倣する手法の提案

-経路選択の成功率向上を意図したネットワークの変更と実験的評価-

A proposal for an imitation method of path-tracking behavior
by end-to-end learning of vision and action

-Modification of network and experimental evaluation aimed at improving
route selection success rate-

2025 年 1 月 19 日 提出

指導教員 林原 靖男 教授

千葉工業大学 先進工学部 未来ロボティクス学科

21C1011 石黒 巧

概要

視覚と行動の end-to-end 学習により
経路追従行動を模倣する手法の提案

-経路選択の成功率向上を意図したネットワークの変更と実験的評価-

本研究室では、移動ロボットのナビゲーション手段を冗長化するために、いくつかの手法を提案している。岡田らはメトリックマップベースの経路追従行動を end-to-end 学習を用いて模倣学習することで、視覚に基づくナビゲーション手法を提案した春山らは、岡田らの手法に加えて、カメラ画像から通路の種類を分類、シナリオによって目標方向を決定し、経路を選択する機能を追加している。ここでのシナリオとは、島田らが提案した、「条件」と「行動」に関する単語を組み合わせて構成された文章を指す。春山らは、島田ら [1] が作成したシナリオ 50 例から 7 例を選定し、そのすべてで視覚に基づいて経路を追従して目的地まで到達できることを確認している。選定外のシナリオでは、地面の色が異なる場所や広場を含んでおり、視覚に基づいて経路追従するのがより困難な環境と考えられる。

本論文では、春山らが対象としていないシナリオでも、目的地までカメラ画像のみを入力として経路追従できるか調査する。はじめに、経路追従の成功率を高めるために、ネットワークの変更や新たな学習方法を導入した。シミュレータを用いた実験によって、これらの手法が経路追従の成功率を上昇させるか検証した。実ロボットを用いた実験によって、春山らが対象としていないシナリオでも目的地まで移動できることを確認した。

キーワード: 自律移動ロボット end-to-end 学習 ナビゲーション

abstract

A proposal for an imitation method of path-tracking behavior
by end-to-end learning of vision and action

-Modification of network and experimental evaluation aimed at improving
route selection success rate

いったん後回し

keywords: autonomouse moblie robot, end-to-end learning, navigation

目次

第 1 章	序論	1
1.1	背景	1
1.2	目的	3
1.3	論文構成	4
第 2 章	要素技術	5
2.1	メトリックマップに基づくナビゲーション	5
第 3 章	関連研究	7
3.1	視覚と行動の end-to-end 学習により経路追従行動をオンラインで模倣する手法	7
3.2	条件付き模倣学習	9
3.3	トポロジカルマップとシナリオ	10
3.4	視覚に基づいて目的地まで経路追従するシステム	12
第 4 章	機能の改善	18
4.1	ネットワークの変更	18
4.2	オフライン学習	20
4.3	シミュレータを用いた実験	20
第 5 章	実験	26
5.1	実験装置	26
5.2	実験方法	27
	5.2.1 実験環境	27

5.2.2	シナリオの選定	28
5.2.3	経路追従モジュールの訓練	32
5.2.4	通路分類モジュールの訓練	32
5.2.5	シナリオに基づくナビゲーション	33
5.3	実験結果	34
第 6 章 おわりに		39
6.1	結論	39
参考文献		40
謝辞		42

図目次

1.1	Imitation method of path-tracking behavior	2
1.2	Experimental environment	3
2.1	Navigation based on metric map	6
3.1	Structure of the Okada and others proposed system	8
3.2	Structure of the network Okada and others used	8
3.3	Two network architectures for command-conditional imitation learning .	9
3.4	Topological map format proposed by Shimada and others	10
3.5	Example scenario proposed by Shimada and others	11
3.6	Overview of proposed system by haruyama and others	12
3.7	Example of topological map and created scenario	14
3.8	Path-following module system	15
3.9	Number of data in the target direction per 10000 steps in the previous experiment	15
3.10	Aggressive meandering	16
3.11	Path-following module system	16
3.12	Scenarios used in the experiment	17
4.1	Structure of the network haruyama and others used	19
4.2	Branched network	19
4.3	Experimental environment	21
4.4	Selecting a path the T-junction	21

4.5	Route for experiment	23
5.1	Experimental setup	27
5.2	Experimental environment	28
5.3	Route used for learning	30
5.4	Experimenta	31
5.5	An example of the robot applied the proposed system	36
5.6	Failed place	37
5.7	Failure point 1	38
5.8	Failure point 2	38

表目次

4.1	Target direction and data for path-following module	19
4.2	Success rate	25
4.3	Success rate at f6 to f7	25
5.1	Number of scenarios excluded	29
5.2	The weights assigned to each class in the experiment	32
5.3	Results of the scenario-based navigation	35

第1章

序論

1.1 背景

移動ロボットにおけるナビゲーションは、目的地までロボットを誘導する制御技術として広く利用されており、物流や、農業、製造業などで活用されている。一般的には、LiDAR や IMU、ホイールエンコーダなど複数のセンサから得られるデータと占有格子地図などのメトリックマップを使用することでロボットを目的地まで制御する。一方で、後述するようにカメラ画像と深層学習に基づくナビゲーション技術の研究も進んでいる。

Felipe ら [2] は視覚を入力とした end-to-end 学習により自動運転を行う手法において、右折や左折といった行動をネットワークの入力に加えることで、性能が向上することを報告している。本研究室の岡田ら [3][4] は、Fig. 1.1 によって、メトリックマップに基づく経路追従行動を視覚を入力として模倣学習することで、視覚に基づく経路追従するシステムを提案した。この手法では、センサとメトリックマップを入力としたルールベース制御器によって生成されたヨー方向の角速度とロボットに取り付けたカメラから取得した RGB 画像をペアにしてデータセットに加えて学習する。学習後はカメラ画像のみを用いて、学習した経路を追従できることが確認されている。

また、春山ら [5] はカメラ画像とシナリオに基づいて、任意の目的地まで経路追従するシステムを提案している。ここでシナリオとは島田ら [1] が提案した、「条件」と「行動」に関する単語を組みわせて構成する文章を指す。春山らの手法では、岡田らの視覚に基づいたナビゲーションに加え、カメラ画像から通路の種類を分類、シナリオによって目標方向を決定し、

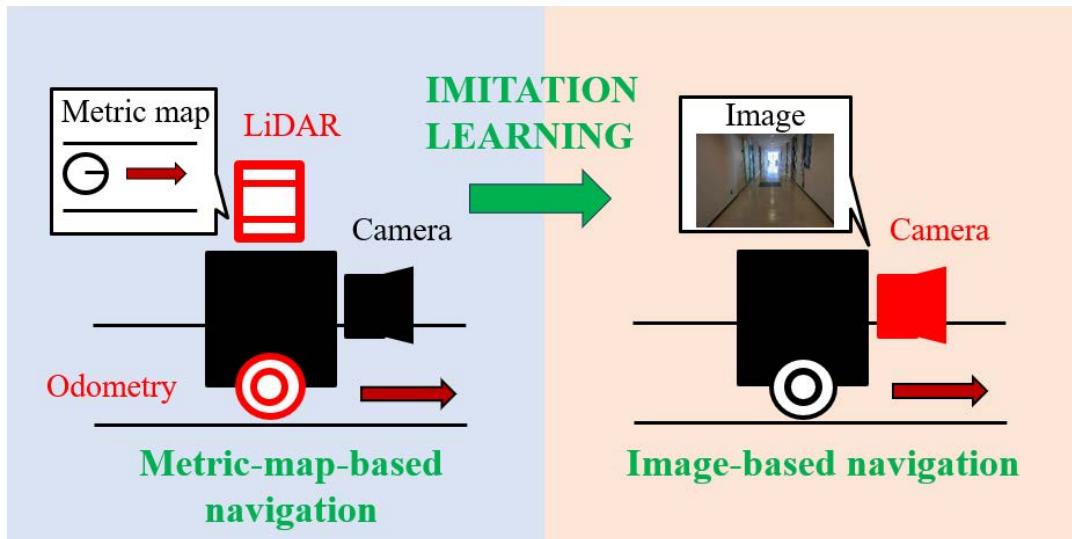


Fig. 1.1: Imitation method of path-tracking behavior

経路を選択する機能を追加している。春山らの先行研究では、島田らが提案した 50 例のシナリオの中から対象としている 7 例すべてで経路追従が可能であることを確認している。

春山らの先行研究では、島田らが作成したシナリオの中で、以下 Fig. 1.2 の青枠で示すエリアを対象としたシナリオを用いている。このエリアはホワイエと呼ばれるスペースを一部を含むものの、壁や床の色が類似しており、一貫性のある環境といえる。一方で Fig. 1.2 の赤色で示すエリアを含むシナリオでは、地面の色が異なるエリアやホワイエを含んでおり、視覚に基づいて経路追従するのがより困難な環境と考えられる。また、春山らの先行研究では対象としたシナリオすべてで目的地まで到達できることが確認されており、失敗の要因は判明していない。失敗する場合は要因を調査することで、システムの改良点について考察できるようになる。

また、カメラ画像と深層学習に基づくナビゲーションの先行研究では、Felipe らが目標方向ごとにモデルを切り替えるネットワークが経路追従の成功率を高められると報告している。提案されたネットワークを使用することで、春山らが使用していたネットワークより経路追従の成功率を向上させることができると可能性がある。

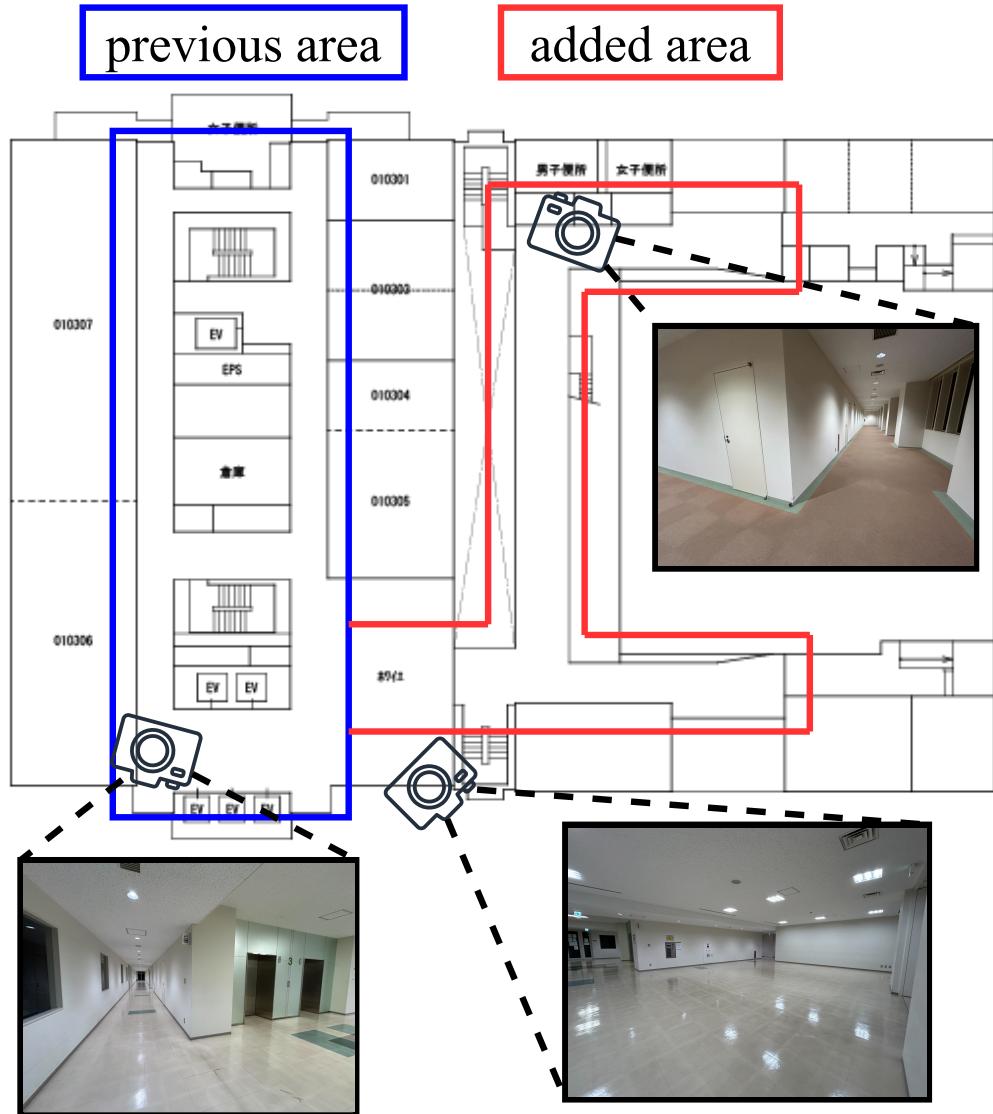


Fig. 1.2: Experimental environment

1.2 目的

本論文では、経路追従の成功率を高めるために春山らのシステムに改良を加え、その手法が経路追従の成功率を上昇させるか検証する。次に、島田らが作成したシナリオの中で春山らが検証していないシナリオでも、目的地までカメラ画像のみを入力として経路追従できるか調査する。

1.3 論文構成

第1章では、先行研究や背景、本論文の目的について述べた。第2章では、本研究に関連する技術について述べる。第3章では、先行研究について述べる。第4章では、先行研究からの変更点について述べ、シミュレータを用いた実験によって有効性を調査する。第5章では、実ロボットを用いた実験について述べる。第6章では、本論文について結論を述べる。

第2章

要素技術

2.1 メトリックマップに基づくナビゲーション

メトリックマップに基づくナビゲーションについて説明する。ナビゲーションを行うためには、LiDAR やオドメトリなどのセンサとメトリックマップを活用し、自己位置推定や経路計画を行うことが必要である。はじめに自己位置推定を行い、ロボットが地図上のどこに位置しているかを特定する。これには、LiDAR やオドメトリデータなどのセンサ情報を利用したアルゴリズムである、AMCL (Adaptive Monte Carlo Localization)などを活用する。次に、推定した自己位置から目的地までの最適な経路を計画し、経路に基づいてロボットを制御する。メトリックマップに基づくナビゲーションでは、事前に取得した環境情報を活用できるという利点がある。Fig. 2.1 にメトリックマップに基づくナビゲーションの例を示す。本論文ではメトリックマップに基づくナビゲーションにより計算される目標角速度を教師として模倣学習を行う。

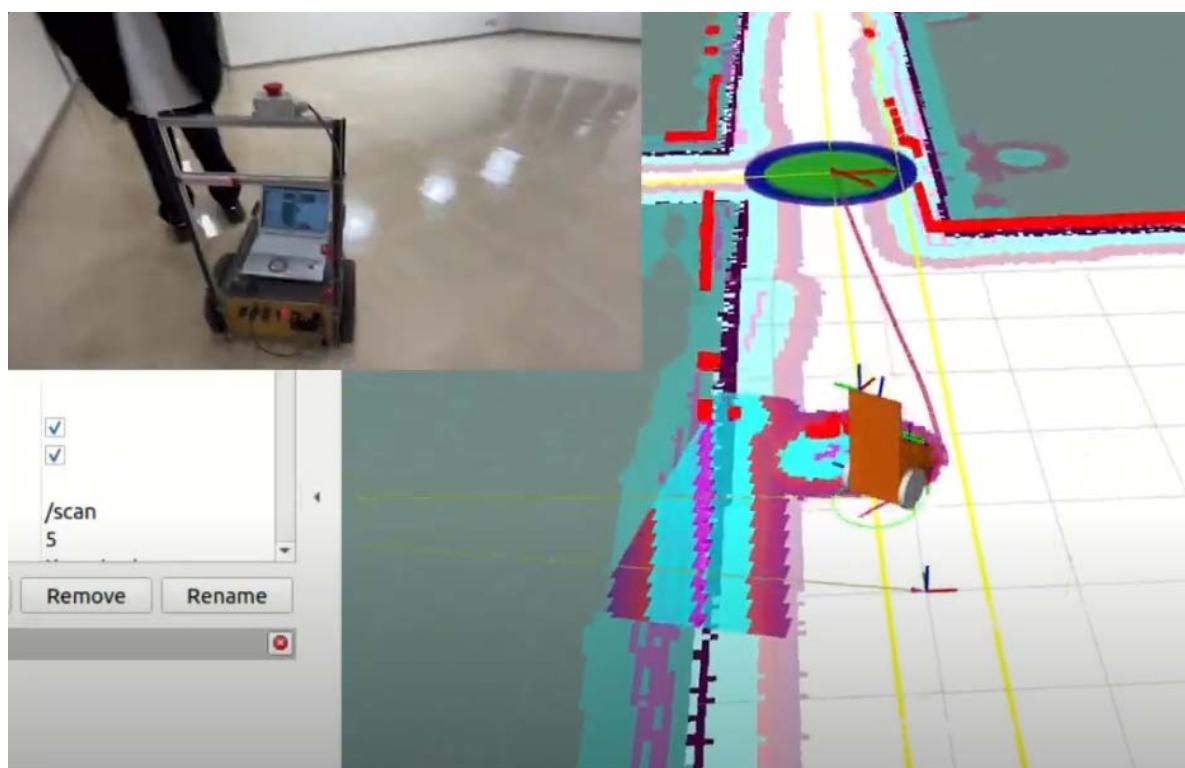


Fig. 2.1: Navigation based on metric map

第3章

関連研究

はじめに，視覚から end-to-end 学習によってナビゲーションを獲得した，岡田らの手法と Felipe らの手法を述べる．次に，島田らが提案したトポロジカルマップの形式，単語の組み合わせによる経路の表現であるシナリオについて述べたのち，春山らの視覚に基づいて目的地まで経路追従するシステムについて述べる．

3.1 視覚と行動の end-to-end 学習により経路追従行動をオンラインで模倣する手法

1 章でも述べたが，本研究室の岡田ら [3] はメトリックマップベースの経路追従行動を end-to-end 学習を用いて模倣学習することで，視覚に基づくナビゲーション手法を提案した．岡田らが提案するシステムを Fig. 3.1 に示す．

訓練時には，ROS の navigation パッケージ [6] を使用して，設定した経路を追従する．ロボットの並進速度は 0.2 m/s に固定する．その際，ロボットに取り付けたカメラから取得した RGB 画像とルールベース制御器が出力するヨー方向の角速度をペアにして，0.2 秒の周期でデータセットに追加する．収集には 3 台のカメラを使用することで，データの多様性を高めるとともに過学習を防ぐ効果を狙っている．また，左右のカメラ画像に対するヨー方向の角速度には経路復帰を補助するためのオフセット ($\pm 0.2\text{rad/s}$) を加える．

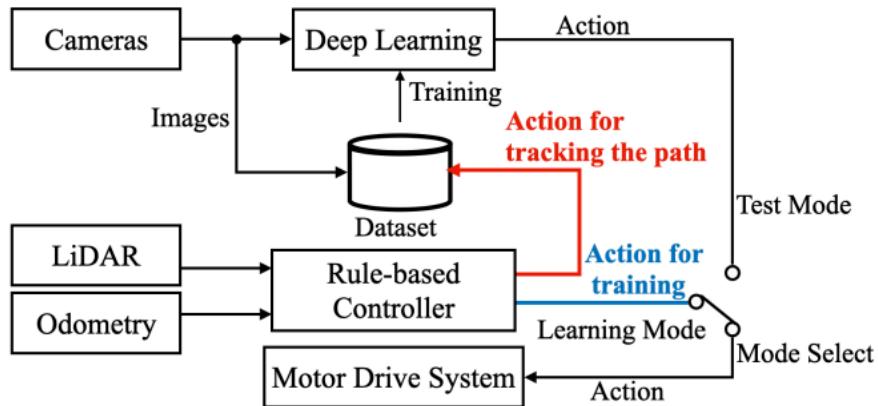


Fig. 3.1: Structure of the Okada and others proposed system (Quoted from [3])

Fig. 3.2 に岡田らの従来手法における学習器のネットワーク構造を示す。ネットワークは、入力層 1, 置み込み層 3, 全結合層 2, 出力層 1 の全 7 層で構成される。データセットからはバッチサイズ 8 で教師データを抽出し、end-to-end 学習を行う。

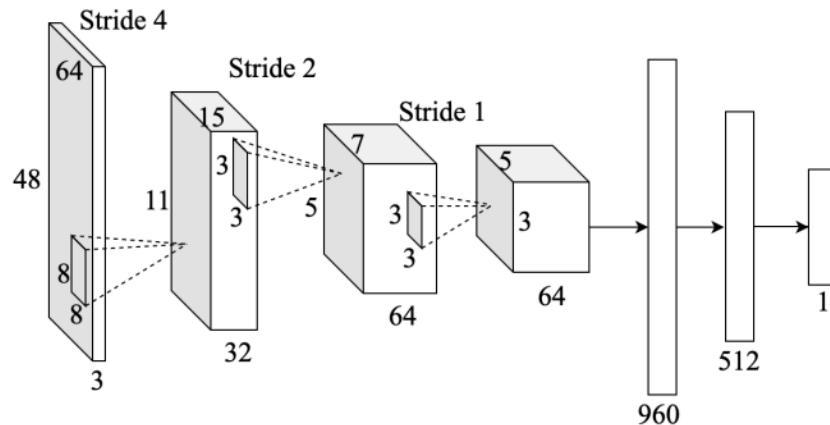


Fig. 3.2: Structure of the network Okada and others used (Quoted from [3])

学習器の訓練後は、中央のカメラから得た RGB 画像を入力とし、出力されるヨー方向の角速度を用いて経路を追従する。この手法は実ロボットを用いて有効性が調査されており、学習した経路を画像のみを入力とした学習器の出力で経路追従できることが確認されている。

3.2 条件付き模倣学習

1章でも述べたが，Felipe ら [2] は視覚を入力とした end-to-end 学習により自動運転を行う手法において，右折や左折といった行動をネットワークの入力に加えることで，性能が向上することを報告している。Felipe らは 2 種類のネットワークを提案している。Fig. 3.3 に示す (a) のネットワークは画像を処理する CNN，そして CNN の出力と観測，目標方向などのコマンドを入力とする全結合層で構成されている。Fig. 3.3 に示す (b) のネットワークは画像を処理する CNN，そして CNN の出力と観測を目標方向などのコマンドによって全結合層を切り替える構造となっている。シミュレータと実環境の両方で実験が行われており，どちらも (b) のネットワークがより優れた結果となった。

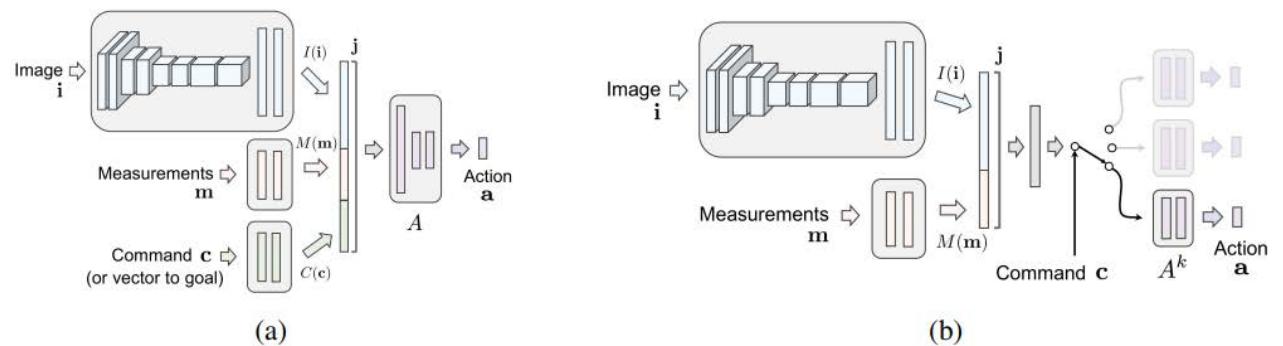


Fig. 3.3: Two network architectures for command-conditional imitation learning
(Quoted from[2])

3.3 トポロジカルマップとシナリオ

トポロジカルマップ

トポロジカルマップとは、環境をランドマークや特徴的な箇所をノードとし、その繋がりをエッジで表現した地図である。島田ら [1] が提案したトポロジカルマップを Fig. 3.4 に示す。提案されたトポロジカルマップでは、ノードは通路の特徴的な箇所に配置され、エッジはノード間を接続する。ノードには ID、通路の特徴 (Type)、エッジ ID と相対角度 (Edge) のデータが含まれ、エッジには ID のみが含まれる。この形式は道案内に関するアンケート結果に基づいており、人が道案内で「通路の特徴」や「向いている方向」を重視することが明らかになったことから生成されている。

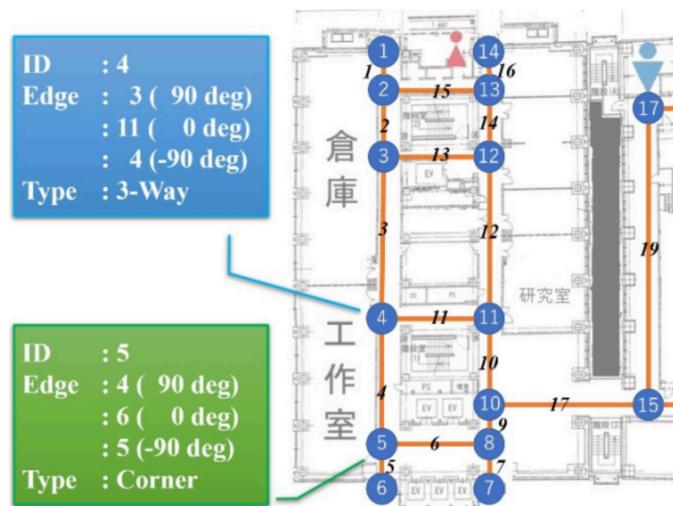


Fig. 3.4: Topological map format proposed by Shimada and others (Quoted from[1])

シナリオ

シナリオは、トポロジカルマップ上の目的地までの経路を「条件」と「行動」の組み合わせで表現する手法である。「条件」は「次の角」や「突き当たりまで」などを指し、「行動」は「直進」や「右折」などを指す。この形式はトポロジカルマップ同様に道案内に関するアンケート結果に基づいており、人が「条件」と「行動」を組み合わせて道案内をすることが明らかになったことから生成されている。例として、Fig. 3.5 に示す経路は「突き当たりまで直進、左折、突き当たりまで直進、停止」と表現される。

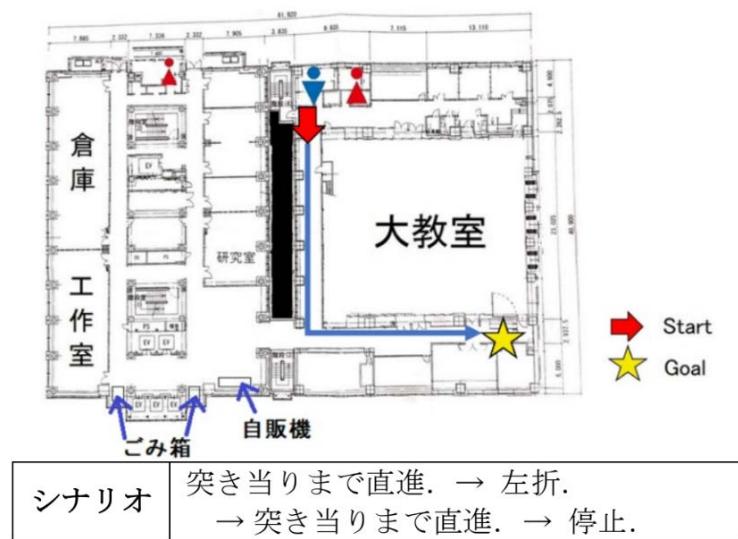


Fig. 3.5: Example scenario proposed by Shimada and others (Quoted from[1])

3.4 視覚に基づいて目的地まで経路追従するシステム

1章でも述べた春山らの手法を述べる。春山らは、カメラ画像とトポロジカルマップから作成されるシナリオに基づいて、目的地まで経路追従するシステムを構築している。提案されたシステムの概要図を Fig. 3.6 に示す。

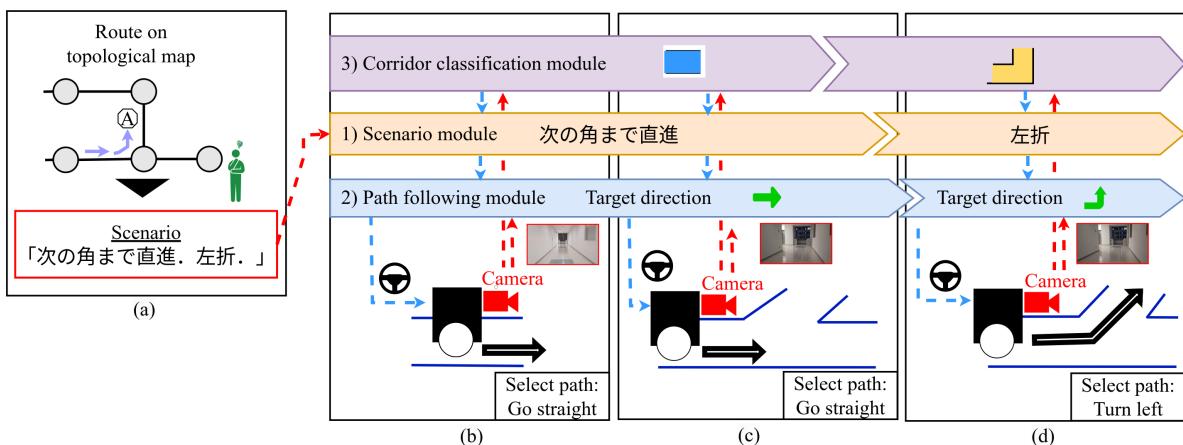


Fig. 3.6: Overview of proposed system by haruyama and others (Quoted from [5])

- 1) シナリオを分解し、「条件」と「行動」を抽出するモジュール（以後、シナリオモジュールと呼ぶ）
- 2) カメラ画像と目標方向を与えることで、経路を追従するモジュール（以後、経路追従モジュールと呼ぶ）
- 3) カメラ画像から通路の特徴を分類するモジュール（以後、通路分類モジュールと呼ぶ）

の3つのモジュールで構成される。ロボットは下記の a から d の一連の流れにより、指示された経路に沿って目的地まで自律移動する。

- (a) トポロジカルマップ上の目的地に応じて、人間が「条件」と「行動」で構成されるシナリオを作成する。例えば、A を目的地とするシナリオは「次の角まで直進. 左折.」となる。
- (b) 作成したシナリオをシナリオモジュールへ入力する。シナリオモジュールは入力された

シナリオを分解し、「条件」と「行動」を抽出する。最初の条件と行動のセットは「次の角まで」と「直進」である。この「直進」を目標方向として経路追従モジュールへ与える。経路追従モジュールは、カメラ画像と与えられた目標方向に基づいて、経路に沿って直進する。

- (c) ロボットが角に近づくと、通路分類モジュールがカメラ画像に基づいて通路を「角」と分類し、それをシナリオモジュールに与える。これにより、シナリオモジュールは「次の角まで」という条件を満たされたことを確認し、次の行動である「左折」へ遷移する。
- (d) 「左折」に基づいて、経路追従モジュールがロボットを制御し、経路に沿って角を左折する。

シナリオモジュール

シナリオモジュールは、トポロジカルマップを基に作成されたシナリオから「条件」や「行動」を抽出し、それを分岐路での目標方向に変換して出力する機能を持つ。トポロジカルマップは、特徴的な通路のノード（青）とそれを繋ぐエッジ（緑）で構成され、ノードには ID や通路の特徴、接続するエッジと方向のデータが含まれ、エッジには ID のみが含まれる。シナリオは目的地までの経路を「条件」と「行動」で表現し、例として「三叉路まで直進・右折・突き当たりまで直進・停止」となる。

シナリオの目標方向への変換では、句点ごとに分解し、「条件」と「行動」を抽出して以下の項目に分類する。

- 1) 通路の特徴（例：「三叉路」「角」）
- 2) 順番（例：「3つ目の」「2番目の」）
- 3) 方向（例：「左手に」「右手に」）
- 4) 行動（例：「右折」「停止」）

Fig. 3.7 に示す例で、「三叉路まで直進」は通路の特徴「三叉路」と行動「直進」に分解される。この処理を経路全体に対して行い、得られた「行動」を分岐路での目標方向として変換し、経路追従モジュールに渡す。また、条件の判定には通路分類モジュールを使用する。

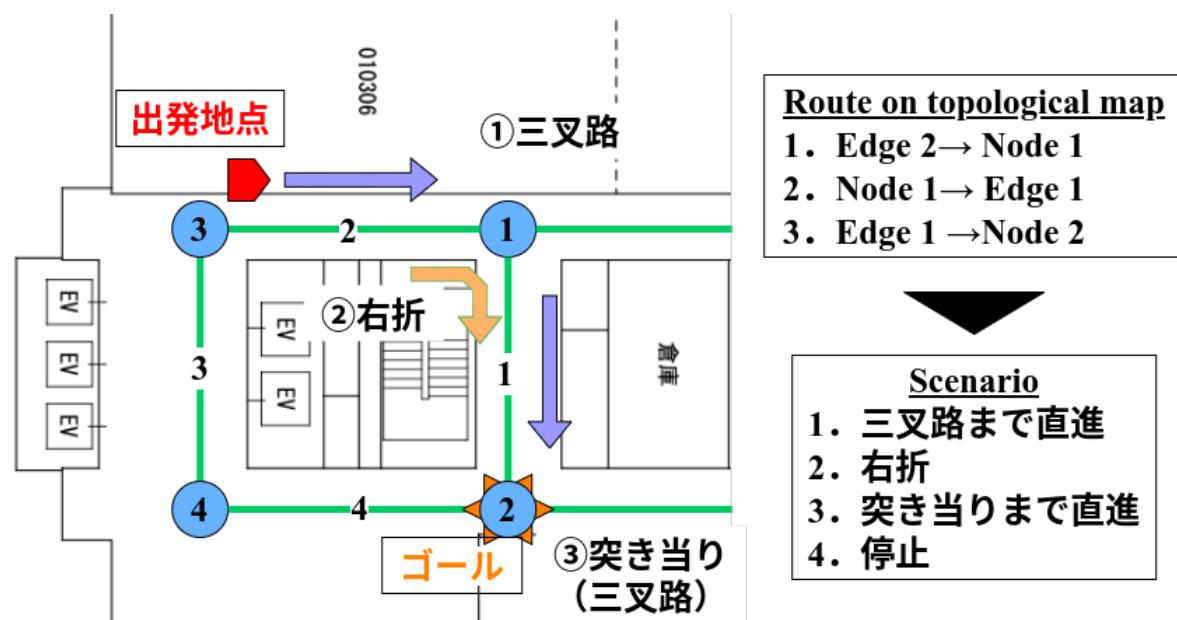


Fig. 3.7: Example of topological map and created scenario (Quoted from [5])

経路追従モジュール

このモジュールは、岡田らの手法に目標方向のデータを加えることで、分岐路で経路を選択し、移動する機能を追加したものである。ここで目標方向とは、目標とする進行方向（「直進」や「右折」）を表す。学習時は、カメラ画像とルールベース制御器が output するヨー方向の角速度、目標方向を 0.2 秒周期でデータセットに加える。データセットから抽出するバッチサイズや、カメラ画像は岡田ら手法と同様である。データセットの収集には藤原ら [7] が提案した、Fig. 3.9 に示す、目標方向が「左折」、「右折」のデータを 7 倍にする手法、Fig. 3.10 に示す、学習時に積極的な蛇行を行う手法を採用する。

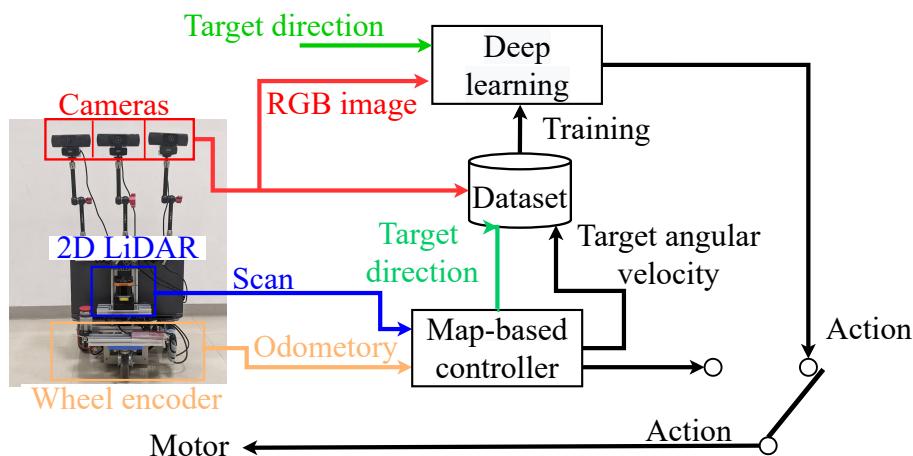


Fig. 3.8: Path-following module system (Quoted from [5])

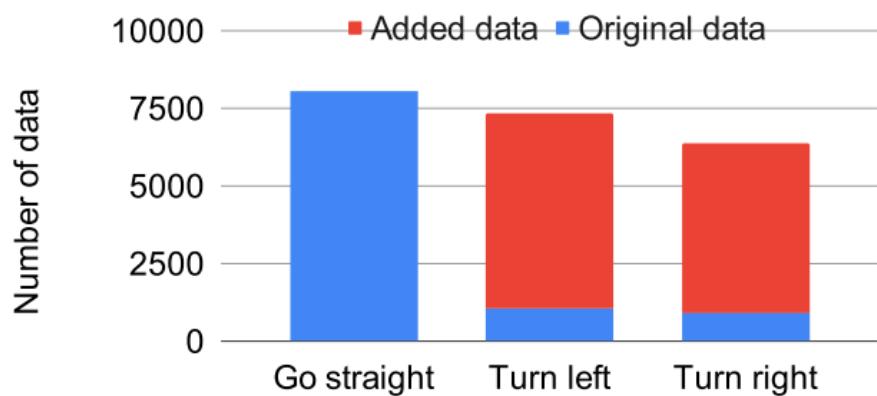


Fig. 3.9: Number of data in the target direction per 10000 steps in the previous experiment(Quoted from [7])

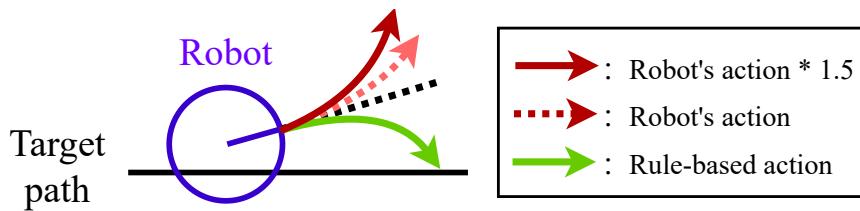


Fig. 3.10: Aggressive meandering(Quoted from [7])

通路分類モジュール

このモジュールでは、ニューラルネットワークを用いることで、カメラ画像を入力として、通路の特徴を分類する。データセットの収集のために、ロボットをルールベース制御器に基づいて走行させる。その際に、フレーム数 16、画像サイズ 64×48 の連続したカメラ画像と通路の分類ラベルを 1 組として、0.125 秒周期でデータセットに加える。通路の分類ラベルのアノテーションはルールベース制御器から出力されるラベルによって自動的に行う。データセット内の不均衡を改善するために、クラス間のデータ数によって重み付けを行うコストアプローチを導入している。

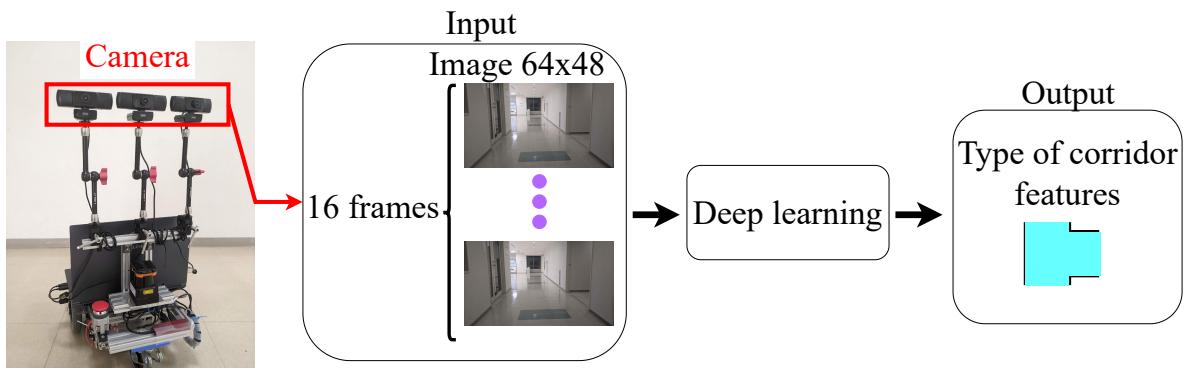


Fig. 3.11: Path-following module system (Quoted from [5])

実ロボットを用いた実験

実ロボットを用いた実験により、ロボットを目的地まで到達可能か検証されている。実験では島田ら用いた 50 例のシナリオの中から、7 例が用いられており、そのすべてでロボットが目的地へ到達できることが確認されている。走行可能なシナリオを Fig. 3.12 に示す。

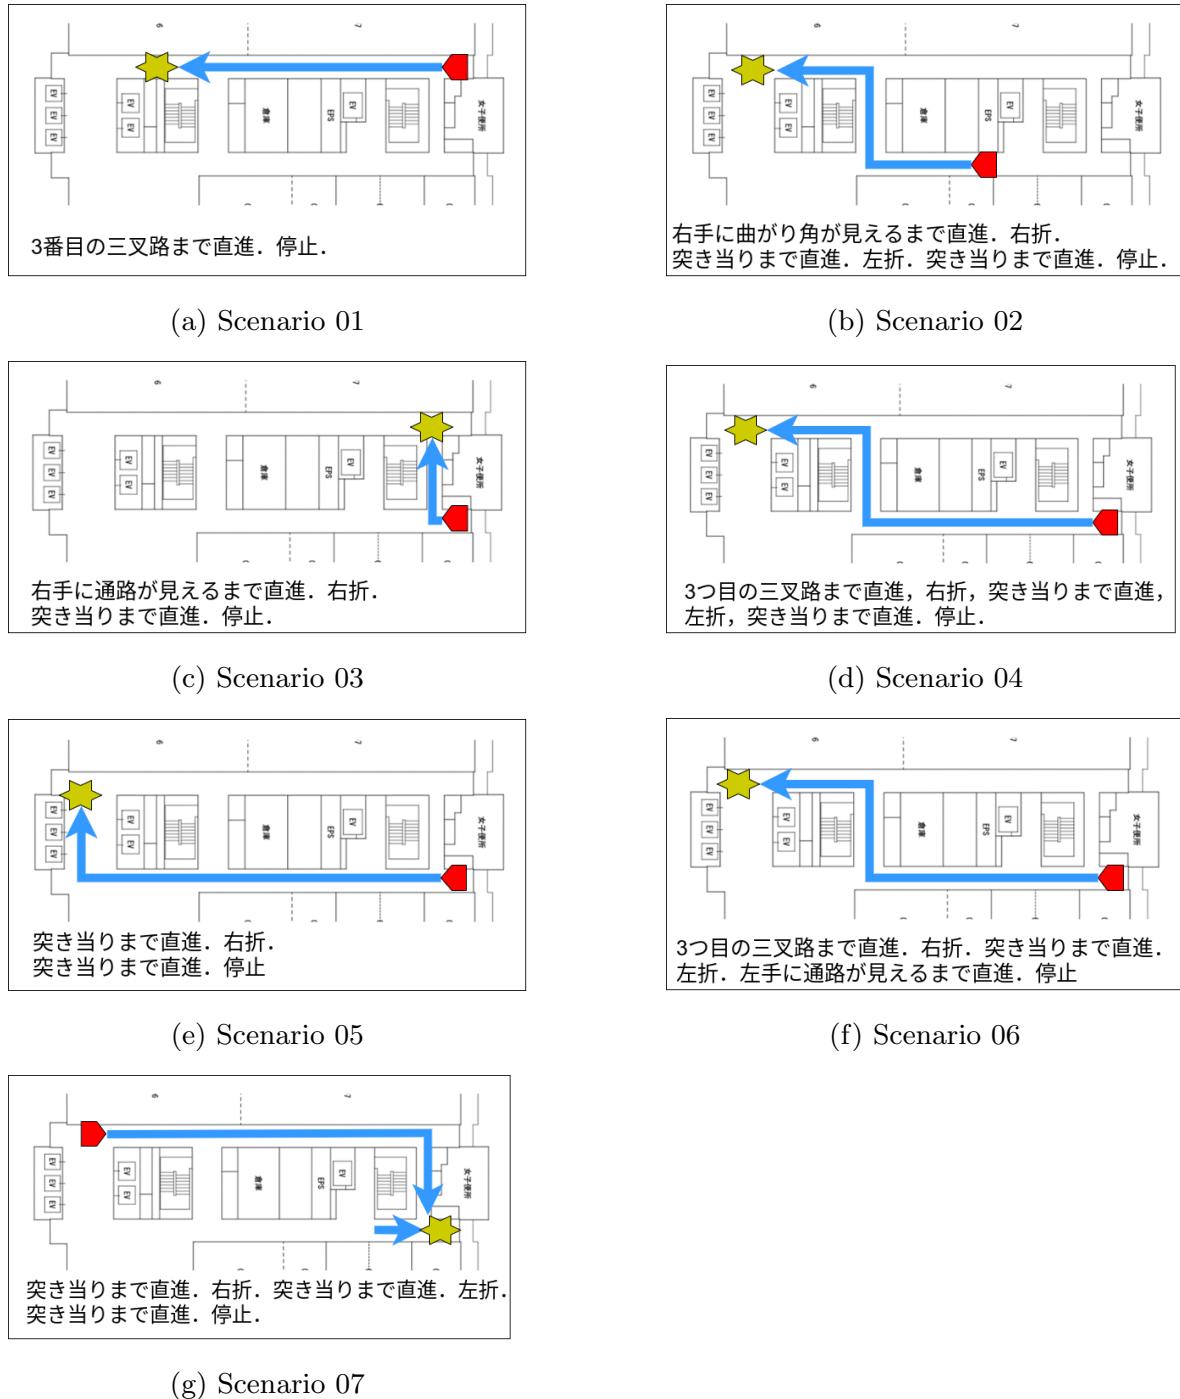


Fig. 3.12: Scenarios used in the experiment (Quoted from [5])

第4章

機能の改善

経路追従モジュールに関して，経路追従の可能性を向上させるために2点変更を加えた．変更点，理由について以下に述べる．また，シミュレータを用いた実験により，それらの手法が経路追従の成功率を上昇させるか検証した．

4.1 ネットワークの変更

春山らの先行研究では，Fig. 4.1 に示すネットワークを使用していた．一方で Felipe らは，コマンドによってモデルを切り替える形式のネットワークがより経路追従の成功率を高められると報告している．そのため，今回の研究では Felipe らによって提案されたネットワークを参考に Fig. 4.2 に示す，ネットワークを構築した．ネットワークの入力は春山らが作成したものと同様の 64×48 の RGB 画像と Table 4.1 に示す，目標方向のワンホットベクトルで，出力はヨー方向の角速度である．また，損失関数や活性化関数などのパラメータは春山らの手法と同様である．

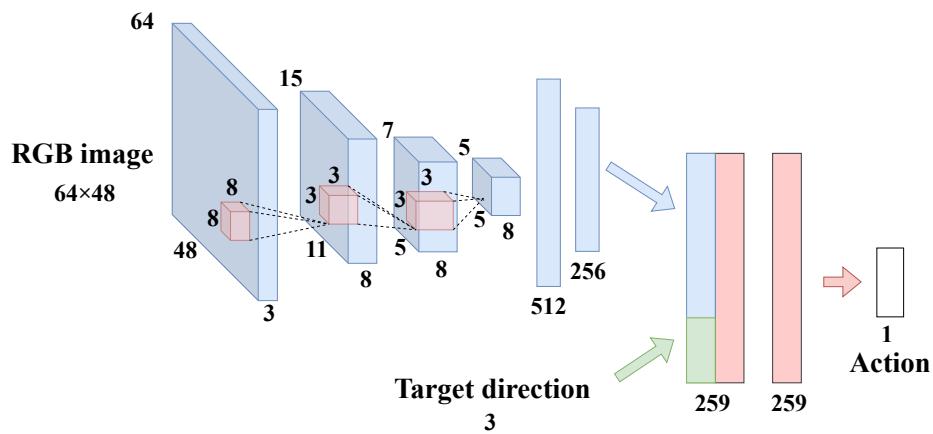


Fig. 4.1: Structure of the network haruyama and others used(Quoted from [7])

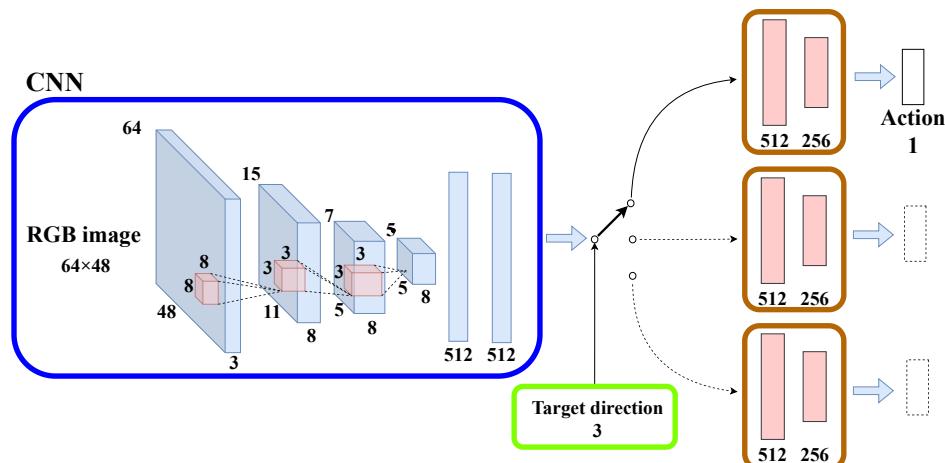


Fig. 4.2: Branched network

Table 4.1: Target direction and data for path-following module

Target direction	Data
Go straight	[1 , 0 , 0]
Turn left	[0 , 1 , 0]
Turn right	[0 , 0 , 1]
Stop	[0 , 0 , 0]

4.2 オフライン学習

春山らの先行研究では学習機の訓練の手法にオンライン学習を用いていた。オンライン学習の欠点として、学習するデータに偏りが発生してしまう点が挙げられる。具体的には、学習の初期に取得したデータは学習される回数が多くなり、学習の後半に取得したデータは学習される回数が減少する。これにより、学習が不十分な場合、経路追従できない箇所が生じることがある。この欠点を補うために、オフライン学習を併用して行う。オフライン学習とは一般的に用いられる学習方法で、予め収集したデータを使用して学習する手法を指す。データを予め収集することにより、すべてのデータを同じ回数学習することが可能である。今回のオフライン学習とは、オンライン学習を最初に行い、そこで作成したデータセットを使用して学習することを意味する。

4.3 シミュレータを用いた実験

まずは、新たに作成したネットワークで経路を正しく選択できるかシミュレータを用いた実験により調査する。次にオフライン学習を追加で行い、効果を検証する。

実験装置

シミュレータに Gazebo[8] を使用する。ロボットには TurtleBot3 Waffle Pi[9] に 3 つのカメラを追加したモデルを用いる。

実験環境

実験環境として Fig. 4.3 に示す、千葉工業大学 2 号館 3 階を模した環境を使用する。経路の選択を行う場所として Fig. 4.3 の A, B の分岐路を対象に行う。Fig. 4.4 に示すように、A, B の各分岐路で経路に侵入するパターンは 3 つ、また脱出するパターンが 2 つあることから合計 12 回の経路選択を行うことができる。

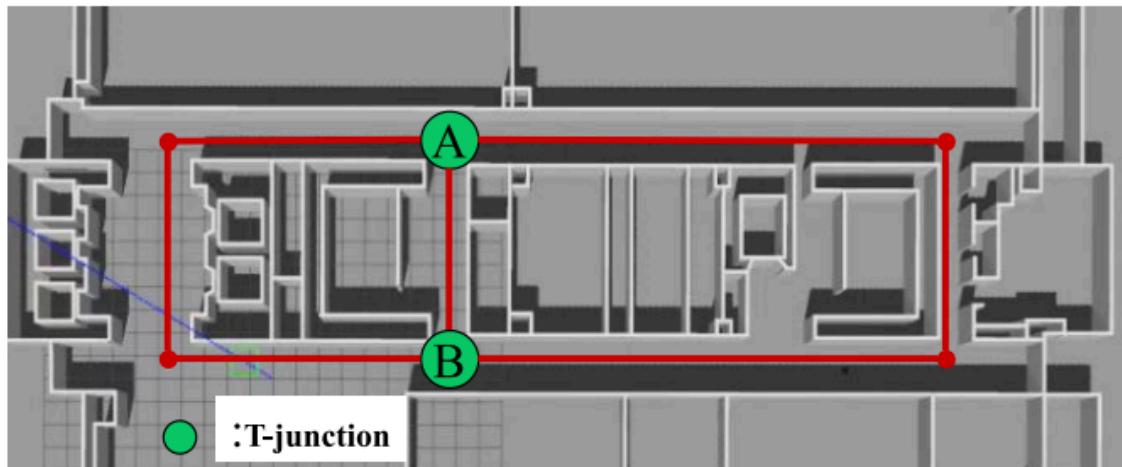


Fig. 4.3: Experimental environment(Quoted from [10])

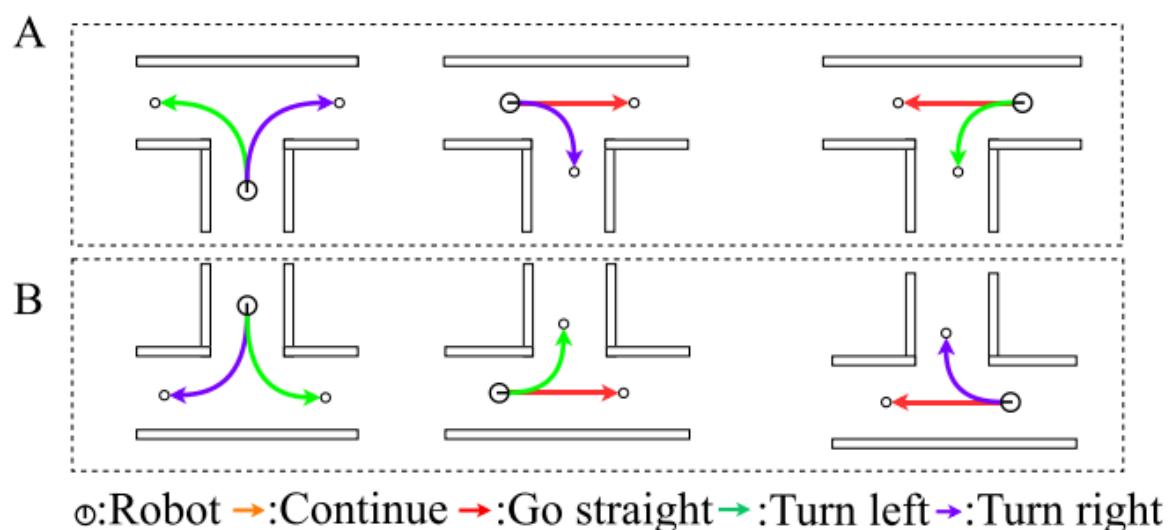


Fig. 4.4: Selecting a path the T-junction(Quoted from [10])

実験方法

Fig. 4.5 に示す経路を， a から f の順番で走行しながら，模倣学習を行う。データセットの収集には，藤原ら [7] が提案している，学習データの不均衡を改善する手法，学習時の積極的な蛇行を行う手法を採用する。テスト時は，学習器の出力で壁に衝突することなく，分岐路の先の経由点に到達することができれば成功とする。オフライン学習に使用するデータセットは，a から f の順番で走行しながらオンライン学習を行った際に作成されるものを使用する。オフライン学習のパラメータとして，バッチサイズはオンライン学習と同様の 8 でデータセットからランダムにデータを抽出し，epoch 数は 10 とする。実験では，学習とテストを繰り返し 10 回行う。

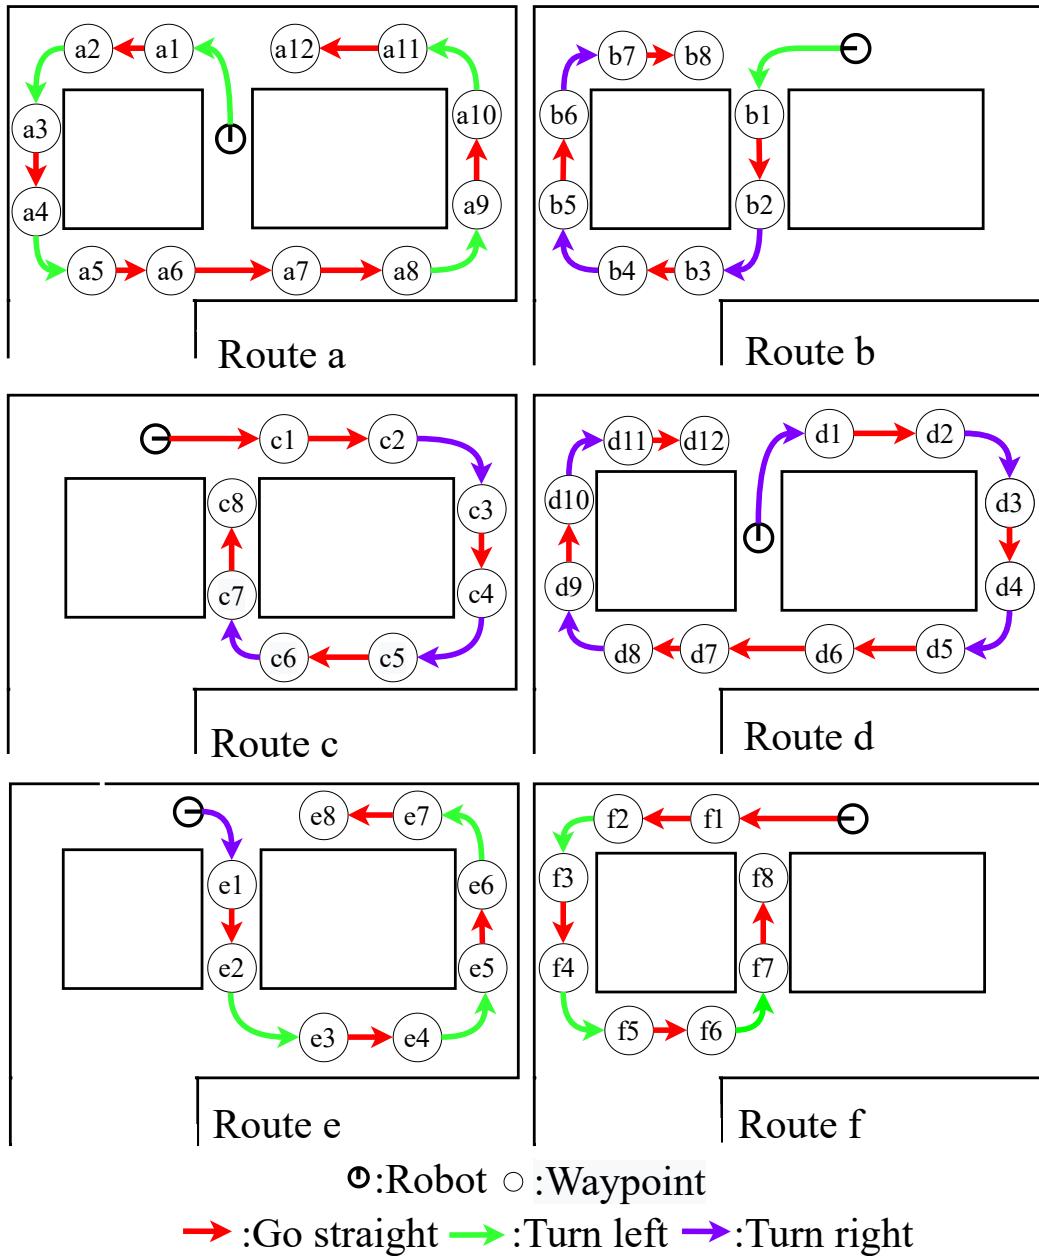


Fig. 4.5: Route for experiment(Quoted from [7])

実験結果

Table 4.2 に結果を示す。表では、春山らが使用していたネットワークを Previous network としている。そして新たなネットワークを使用した実験を Branched とした。

新たに作成したネットワークでも、経路を正しく選択することが確認できた。step 数が 10000 の場合は、先行研究の手法と比較すると成功率が上昇した。しかし step 数が 20000 の場合は先行研究と成功率に大きな差は生じなかった。

10000 step オンライン学習を行い、10 epoch オフライン学習を併用した場合では、成功率がオンライン学習を 20000 step 行った際と同等になった。一方で、オンライン学習の欠点であったルートの後半部分での失敗が減少した。具体的には Branched を使用して 10000 step の実験を行った際に一番失敗の多い箇所であった、Fig. 4.5 の Route f の f6 から f7 にかけての経路選択の成功率が向上した。Table 4.3 に、それぞれの実験での f6 から f7 にかけての経路追従の成功率を示す。

学習にかかる時間に注目すると、オンライン学習を 20000 step 行った際は 60 分だったのが、オンライン学習を 10000 step、オフライン学習を行う場合では～～となった。オフライン学習を併用することで、経路追従の成功率を維持しながらも、学習にかかる時間を短縮することができた。

オフライン学習を併用する手法が、20000 step と同様の結果として、今回使用したルートは 9500step 程で 1 周できることが理由として考えられる。9500 step を超えると、一度も走行していない箇所がなくなり、

これらの結果から、従来の手法では 20000 step 走行しながら学習していたものを、10000 step まで減らすことができたと言える。ネットワークの変更やオフライン学習は経路追従の成功率を向上させるには有効であると考えられる。

Table 4.2: Success rate

Experiment	Step + Epoch	Total result
Previous network	10000	109/120 (90.8%)
	20000	114/120 (95.0%)
Branched	10000	113/120 (94.2%)
	20000	115/120 (95.8%)
Branched +	10000 + 10	115/120 (95.8%)
Offline learning		

Table 4.3: Success rate at f6 to f7

Experiment	Step + Epoch	Total result
Branched	10000	5/10
	20000	7/10
Branched +	10000 + 10	8/10
Offline learning		

第5章

実験

春山らが未検証のシナリオに関しても，目的地へ到達可能か実ロボットを用いた実験で検証する.

5.1 実験装置

Fig. 5.1 に実験に使用する icart-mini[11] をベースに開発したロボットを示す. ロボットには以下に示すセンサ， PC を搭載している .

- 1) ウェブカメラ (サンワサプライ株式会社 CMS-V43BK)
- 2) 2D-LiDAR (北陽電機 UTM-30LX)
- 3) PC (GALLERIA GCR2070RGF-QC-G)
- 4) エンコーダ

メトリックマップに基づくルールベース制御器には，本学で ROS Navigation stack を基に開発した orne navigation[12] を使用する .



Fig. 5.1: Experimental setup

5.2 実験方法

5.2.1 実験環境

実験環境として Fig. 5.2 に示す千葉工業大学 2 号館 3 階を用いる。環境中には、三叉路が 6 つ、角が 3 つ、突き当りが 4 つ含まれている。また、経路追従モジュールと通路分類モジュールの学習データを収集するために、Fig. 5.3 に示すルートを走行する。

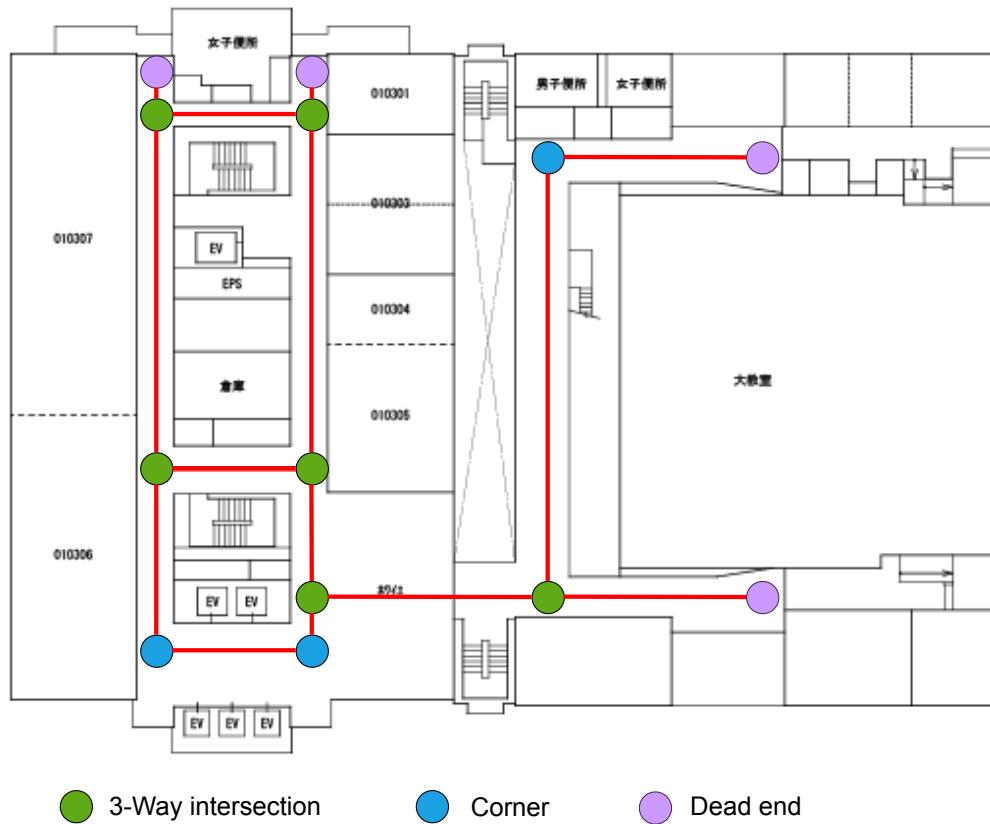


Fig. 5.2: Experimental environment

5.2.2 シナリオの選定

実験に使用するシナリオを，島田らが作成した 50 例から選定した。選定するにあたって，以下の条件を設定した。

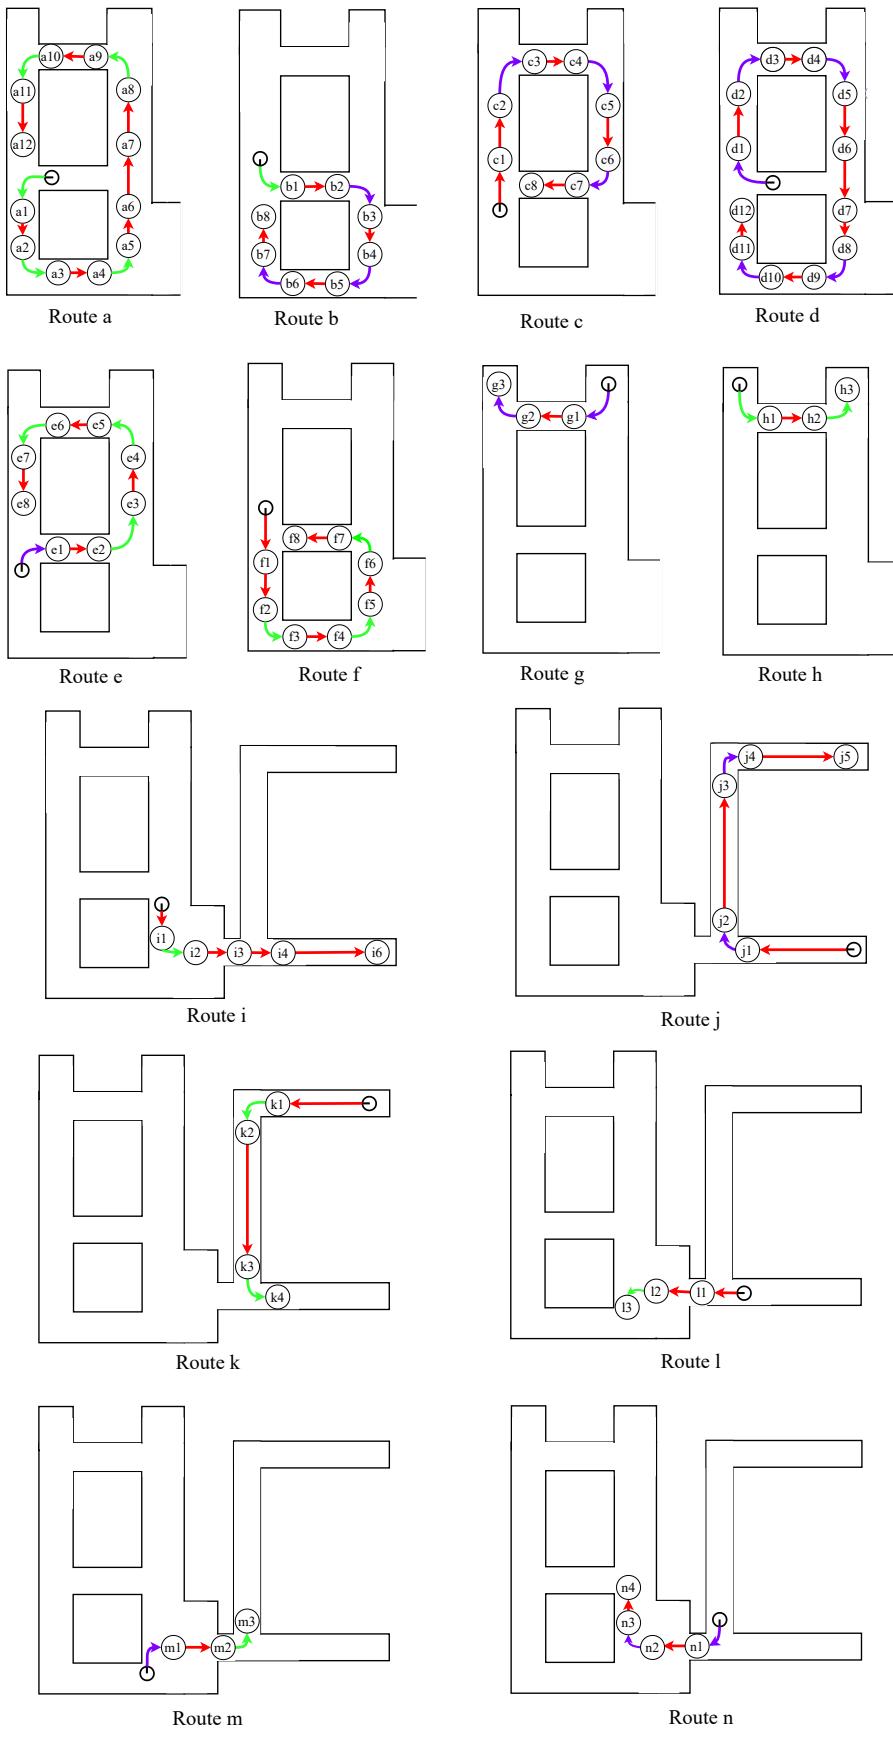
- 1) ロボットが移動するには通路が狭すぎて，衝突せずに走行するのが困難な，Fig. 5.4 上部に示す部分を走行ルートに含まれないこと。
- 2) 現時点の経路追従モジュールでは対応していない，「後ろを向く」などその場での旋回が含まれていないこと。
- 3) ロボットが移動しても，カメラ画像の特徴の変化が小さいため，通路の種類の分類が困難な Fig. 5.4 下部に示す部分がスタート地点では無いこと。
- 4) スタート地点が Fig. 5.4 に示す箇所でないこと。この箇所がスタート地点のシナリオ

は、「左手に通路が見えるまで直進」「右手に通路が見えるまで直進」である。現時点の路分類モジュールの入力である正面のカメラ画像からでは、ロボットが移動してもカメラ画像の特徴の変化が小さく、シナリオの条件を満たす路分類結果が得られない可能性がある。

条件ごとの除外したシナリオ数を Table 5.1 に示す。また、条件 2 と 3 の両方を満たしたシナリオが 2 つある。これにより、選定されたシナリオ数は 28 例となる。

Table 5.1: Number of scenarios excluded

reason	number of scenario
1	4
2	7
3	13



Ⓐ:Robot →:Go straight ↗:Turn left ↛:Turn right

Fig. 5.3: Route used for learning

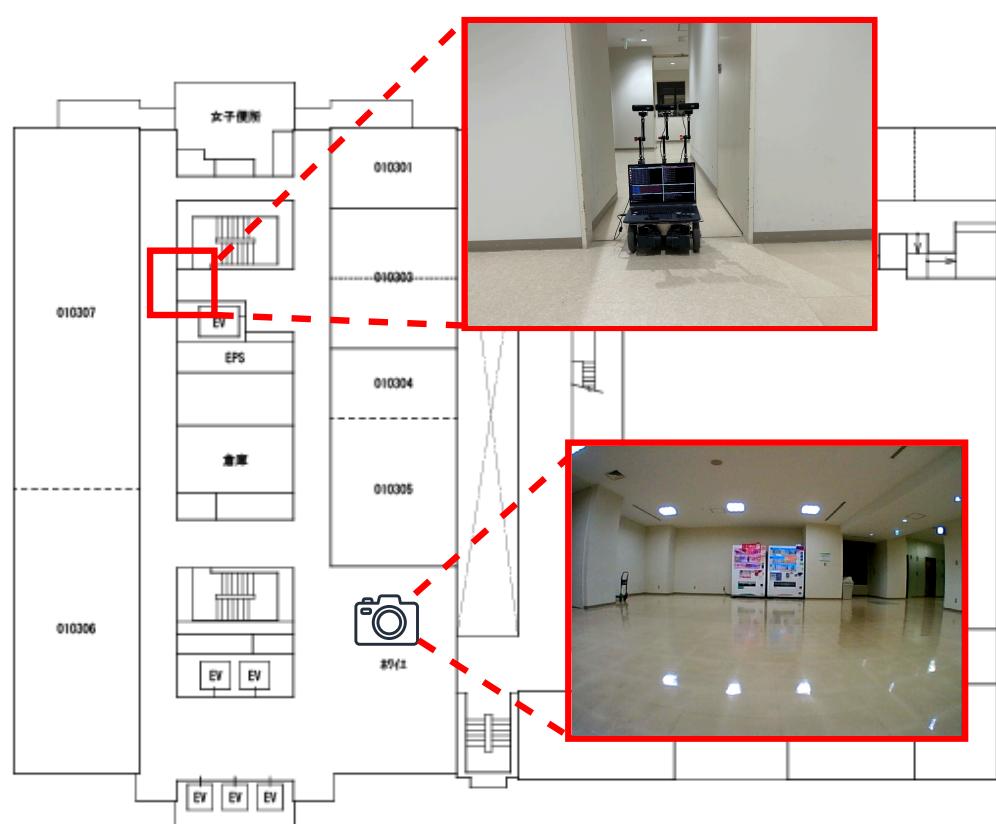


Fig. 5.4: Experimental

5.2.3 経路追従モジュールの訓練

Fig. 5.3 に示すルートをオンライン学習させながら 1 周走行する。データセットの収集には藤原ら [7] が提案する手法を用いる。また、オンライン学習で作成したモデルに追加でオフライン学習を行う。オフライン学習時のデータセットにはオンライン学習の際に作成したルート 1 周分のデータを用いる。データセットからはオンライン学習と同様のバッチサイズ 8 でデータをランダムに取得し、epoch 数は 20 とした。

5.2.4 通路分類モジュールの訓練

Fig. 5.3 に示すルートを ROS の navigation パッケージを使用して、経路を 1 周する。その際、3 つのカメラからそれぞれ画像データを収集しながら走行する。学習時のパラメータとして、バッチサイズを 32、epoch 数を 30 とし、コストアプローチに用いた重みは Table 5.2 に示す。

Table 5.2: The weights assigned to each class in the experiment

Class	Class weights
直進	1
突き当たり	39.5
角(右)	14
角(左)	14.2
十字路	1
三叉路(右)	6.6
三叉路(中央)	7.0
三叉路(左)	6.4

5.2.5 シナリオに基づくナビゲーション

2つのモジュールを訓練後，ロボットが目的地まで到達できるか確認する。実験では，ロボットをシナリオのスタート地点，向きに配置し，シナリオを1例ずつ入力する。壁に衝突することなく正しい経路を選択し，目的地で停止した場合に成功とする。

5.3 実験結果

選定したシナリオ 28 例中，24 例の成功を確認した。Table 5.3 に全シナリオの走行の成否を示す。また，1 例として Scenario35 を走行時の実験の様子を Fig. 5.5 に示す。

先行研究で経路追従を確認していないエリアを含むシナリオでも，経路追従することが確認できた。また，ロボットがシナリオの道順に沿って，分岐路で適切な経路を選択する様子が確認できた。

Table 5.3: Results of the scenario-based navigation

scenario	success or failure
1	
3	✗
4	✗
5	
6	
9	✗
20	
21	
22	
24	
25	
27	
28	
29	
30	
31	
32	
33	
34	✗
35	
36	
37	
38	
39	
40	
41	
42	
50	



Fig. 5.5: An example of the robot applied the proposed system

失敗した4例では、曲がり角で左折すべきところを直進した。Fig. 5.6に失敗した箇所を示す。失敗した4例の内訳として、Fig. 5.6の青枠に示す失敗が3例、緑枠に示す失敗が1例となった。失敗した箇所でも通路の特徴の分類は正しく行われており、経路追従モジュールに与える目標方向も正しい値が入力されていた。失敗の原因として、通路分類モジュールの出力に遅れがあることが考えられる。失敗箇所において、学習時とテスト時に「左折」の目標方向を与えたタイミングのロボットの位置をFig. 5.7とFig. 5.8に示す。学習時は角から1~2mほど前方で目標方向を与えているのに対し、テスト時では角から0.2~0.5mまで近づいてから与えられていることがわかった。経路追従モジュールに目標方向が与えられるタイミングは、通路分類モジュールの出力が変化したタイミングとなる。つまり通路の分類が遅れることで目標方向が与えるタイミングが遅くなり、曲がることができないと考えた。確認として、学習時と同じタイミングで経路追従モジュールに目標方向を与えた場合では曲がる様子が確認できた。これより、失敗した要因として通路分類モジュールの出力に遅れがあることが考えられる。

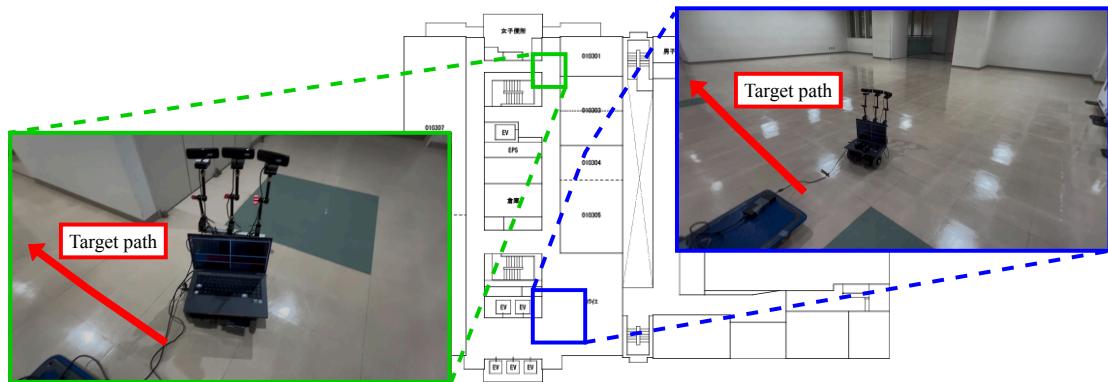
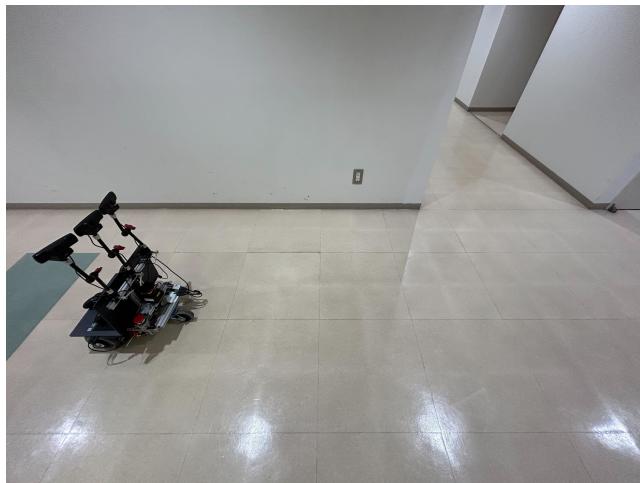


Fig. 5.6: Failed place



(a) Location of label changes during learning

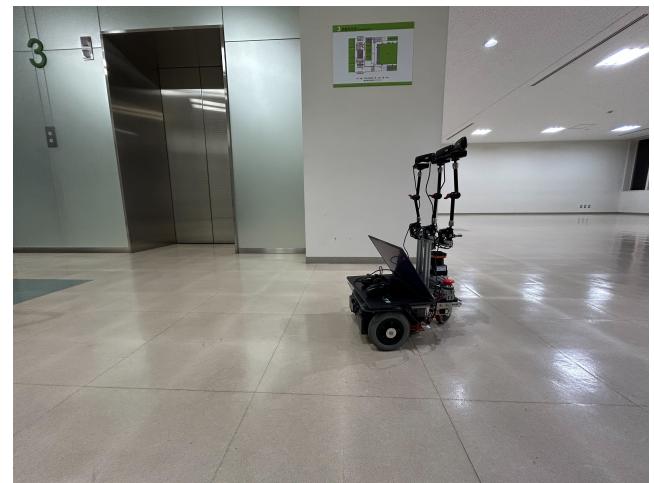


(b) Location of label changes during testing

Fig. 5.7: Failure point 1



(a) Location of label changes during learning



(b) Location of label changes during testing

Fig. 5.8: Failure point 2

第6章

おわりに

6.1 結論

本論文では、春山らが提案したシステムを改良し、先行研究では走行が未確認であったシナリオに対しても目的地までカメラ画像のみを入力として経路追従可能か検証した。経路追従の成功率を向上させることを目的として、先行研究からは、行動ごとにモデルを切り替えるネットワークに変更、オンライン学習による追学習する仕組みを追加した。また、これらの手法が経路追従の成功率を向上させることを、シミュレータでの実験で検証した。実口ボットを用いた実験では、先行研究では走行が確認されていないエリアをシナリオを含む場合でも28例中、24例は目的地まで経路追従が可能であること確認した。失敗した4例に関して、通路分類モジュールの出力が遅れることによって、経路追従に失敗すると考えられる。

参考文献

- [1] 島田滉己, 上田隆一, 林原靖男. トポロジカルマップを用いたシナリオによるナビゲーションの提案-シナリオに基づく実ロボットのナビゲーション-. 計測自動制御学会 SI 部門講演会 SICE2020 予稿集, pp. 1H2–04, 2020.
- [2] Felipe Codevilla, Matthias Müller, Antonio López, Vladlen Koltun, Alexey Dosovitskiy. End-to-end driving via conditional imitation learning. 2018.
- [3] 岡田眞也, 清岡優祐, 上田隆一, 林原靖男:. 視覚と行動の end-to-end 学習により経路追従行動をオンラインで模倣する手法の提案. 計測自動制御学会 SI 部門講演会 SICE-SI2020 予稿集, pp. 1147–1152, 2020.
- [4] 岡田眞也, 清岡優祐, 春山健太, 上田隆一, 林原靖男. 視覚と行動の end-to-end 学習により経路追従行動をオンラインで模倣する手法の提案-経路追従行動の修正のためにデータセットを動的に追加する手法の検討-. 計測自動制御学会 SI 部門講演会 SICE-SI2021 予稿集, pp. 1066–1070, 2021.
- [5] 春山健太, 藤原恆, 馬場琉生, 石黒巧, 上田隆一, 林原靖男. 視覚と行動の end-to-end 学習により経路追従行動をオンラインで模倣する手法の提案-トポロジカルマップとシナリオに基づく経路選択機能の追加と検討-. 計測自動制御学会 SI 部門講演会 SICE2023 予稿集, pp. 1B4–03, 2023.
- [6] ros planning. Ros navigation stack. code for finding where the robot is and how it can get somewhere else. <https://github.com/ros-planning/navigation>. (Accessed on 12/20/2023).
- [7] 藤原恆, 春山健太, 馬場琉生, 上田隆一, 林原靖男. 視覚と行動の end-to-end 学習により経路追従行動をオンラインで模倣する手法の提案-実環境における経路選択機能の検証と学習時間の短縮化の検討-. 日本機械学会ロボティクス・メカトロニクス講演会'23 予稿集,

- pp. 2P2-G06, 2023.
- [8] Gazebo. Gazebo. <https://gazebosim.org/home>. (Accessed on 12/20/2023).
 - [9] ROBOTIS-GIT. turtlebot3. <https://github.com/ROBOTIS-GIT/turtlebot3>. (Accessed on 12/20/2023).
 - [10] 春山健太, 藤原恆, 清岡優祐, 岡田眞也, 上田隆一, 林原靖男. 視覚と行動の end-to-end 学習により経路追従行動をオンラインで模倣する手法の提案-経路選択機能の追加-. 日本機械学会ロボティクス・メカトロニクス講演会'22 予稿集, pp. 2P2-L05, 2022.
 - [11] T frog Project. icart_mini. https://t-frog.com/products/icart_mini/. (Accessed on 12/20/2023).
 - [12] open rdc. orne_navigation. https://github.com/open-rdc/orne_navigation.git. (Accessed on 12/20/2023).

謝辞

本研究を進めるにあたり，幾度も研究相談や貴重なアドバイスをくださった林原靖男教授に，心より感謝申し上げます．未熟な私でしたが，丁寧にご指導いただいたおかげで，卒業論文という形にまとめることができました．

また，実験を手伝っていただいた佐藤君，塩田君，石原君には，多大なご協力をいただきました．特に，夜遅くまで実験に付き合ってくださったことには感謝の念に堪えません．本当にありがとうございました．

最後に，大学生活全般を支え，常に励ましてくれた両親に深く感謝します．